Índice

1. Procesos estocásticos y datos de series temporales **2**
1.1. Datos de sección cruzada vs datos de series temporales 3
1.2. El desafío 3

2. Estacionariedad **5**
2.1. Estacionariedad en sentido débil 5
2.2. Función de autocovarianzas y función de autocorrelación 6

3. Transformaciones de realizaciones de procesos estocásticos NO estacionarios **7**
3.1. Internat. airline passengers: monthly totals in thousands. Jan 49 Dec 60 7
3.1.1. Trasformación logarítmica de los datos 8
3.1.2. Primera diferencia del logarítmo de los datos 9
3.1.3. Diferencia estacional de la primera diferencia del logarítmo de los datos . . . 10
3.2. Tasa logarítmica de crecimiento 11
3.2.1. Comentarios y/o interpretaciones de los datos transformados 11

Lección 1. Transformación de datos

Marcos Bujosa

4 de agosto de 2025

Resumen

En esta lección veremos algunas transformaciones de los datos para *"hacerlos estacionarios"*; y daremos interpretación a los datos transformados.

- lección en html
- lección en mybinder

Carga de algunos módulos de python y creación de directorios auxiliares

```
# Para trabajar con los datos y dibujarlos necesitamos cargar algunos módulos de python
import numpy as np # linear algebra
import pandas as pd # data processing, CSV file I/O (e.g. pd.read_csv)
import matplotlib as mpl
# definimos parámetros para mejorar los gráficos
mpl.rc('text', usetex=False)
import matplotlib.pyplot as plt   # data visualization
```

- Creación del directorio auxiliar para albergar las figuras de la lección Para publicar la lección como pdf y como página web, necesito los gráficos en forma de ficheros `.png` alojados en un directorio específico:

```
imagenes_leccion = "./img/lecc01" # directorio para las imágenes de la lección
import os
os.makedirs(imagenes_leccion, exist_ok=True) # crea el directorio si no existe
```

1. Procesos estocásticos y datos de series temporales

Proceso estocástico es una secuencia de variables aleatorias, X_t donde el índice t recorre el conjunto de números enteros ($\mathbb{Z}$).

$$\boldsymbol{X} \;=\; (\ldots, X_{-2}, X_{-1}, X_0, X_1, \ldots) \;=\; (X_t \mid t \in \mathbb{Z});$$

Muestra es una secuencia *finita* de datos (valores).

$$\boldsymbol{x} = (x_1, x_2, \ldots x_n)$$

- Consideraremos cada dato x_t como una *realización de* X_t.

- Consecuentemente, consideraremos que una *muestra* es una *realización de un tramo finito* de un proceso estocástico:

$$(x_1, x_2, \dots x_n) \text{ es una realización de } (X_t \mid t = 1 : n).$$

Nótese que en el **proceso estocástico** el índice t recorre los infinitos números enteros mientras que en la **muestra** solo recorre los naturales entre 1 y n.

1.1. Datos de sección cruzada vs datos de series temporales

Consideremos dos tipos de muestras $\boldsymbol{x} = (x_1, x_2, \dots x_n)$:

Sección cruzada el índice NO es cronológico. La numeración (la indexación) de cada dato es solo una *asignación arbitraria de etiquetas* que identifican a cada individuo, empresa, objeto, etc. que ha sido medido. Consecuentemente:

- *el orden en el que aparecen los datos de la muestra es irrelevante.*
- conocer el índice de un dato no permite deducir nada respecto de cualquier otro dato de la muestra.

Series temporales Corresponden a mediciones de un mismo objeto a lo largo del tiempo. El índice indica el instante de cada medición. *Es habitual que el orden cronológico de los datos sea importante* para explicar cada uno de ellos.

- con frecuencia la medición en un instante de tiempo está relacionada con otras mediciones próximas en el tiempo. En tal caso...
- no deberemos asumir que las variables aleatorias del proceso estocástico subyacente, $\boldsymbol{X} = (X_t \mid t \in \mathbb{Z})$, sean independientes.

1.2. El desafío

El análisis de *series temporales* trata sobre la inferencia estadística de muestras que **frecuentemente NO podemos asumir que sean realizaciones** de variables aleatorias *i.i.d.* (*independientes e idénticamente distribuidas*).

Así pues, aunque

- el marco ideal para el análisis es que la serie temporal "**sea estacionaria**"(!!),
  (!! *abuso del lenguaje que expresa que podemos asumir que la serie es una realización de un proceso estocástico estacionario, es decir, cuyos momentos no dependen del índice* t. Veremos una definición formal en lecciones posteriores).

- lo habitual es que, por distintos motivos, **NO lo sea**.

```
path = '../datos/'
df1 = pd.read_csv(path+'PIB_UEM.csv')
df2 = pd.read_csv(path+'ProduccionCemento.csv')
df3 = pd.read_csv(path+'IBEX35.csv')
df4 = pd.read_csv(path+'ExportacionDeAcero.csv')
```

```
df1.plot(x='obs',xlabel='',figsize=(15,4)).set_title('PIB zona euro',fontsize=18)
plt.savefig('./img/lecc01/PIB_UEM.png', dpi=300, bbox_inches='tight')
```

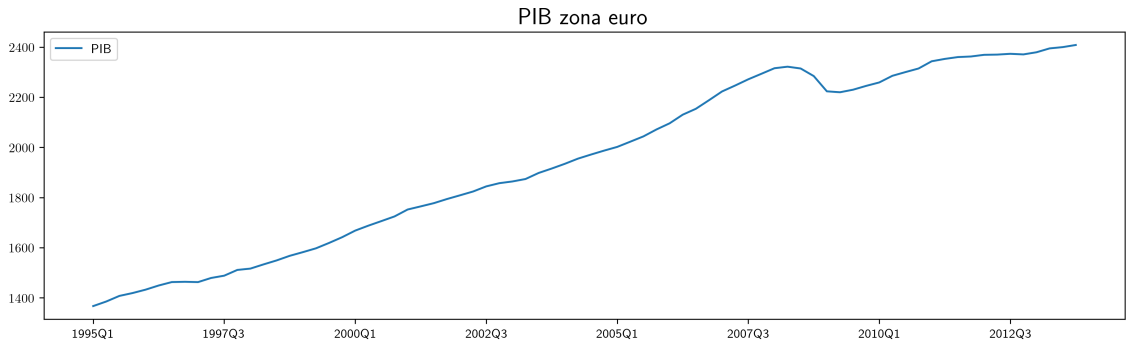


```
df2.plot(x='obs',xlabel='',figsize=(15,4)).set_title('Producción de cemento en España',fontsize=18)
plt.savefig('./img/lecc01/ProduccionCemento.png', dpi=300, bbox_inches='tight')
```

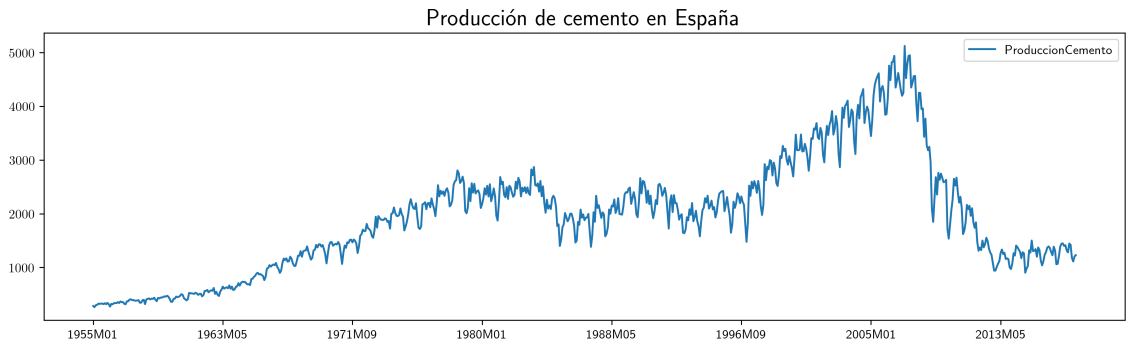


```
df3.plot(x='obs',xlabel='',figsize=(15,4)).set_title('Rendimiento porcentual diario del IBEX 35',fontsize=18)
plt.savefig('./img/lecc01/IBEX35.png', dpi=300, bbox_inches='tight')
```

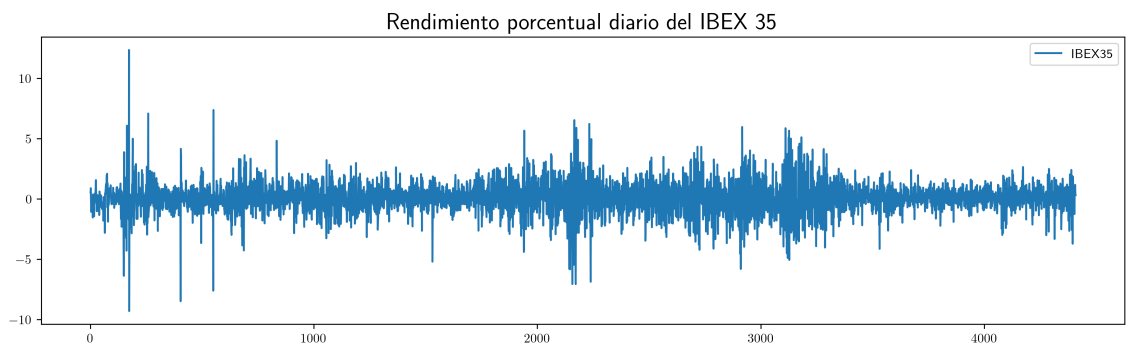


```
df4.plot(x='obs',xlabel='',figsize=(15,4)).set_title('Exportaciones españolas de acero',fontsize=18)
plt.savefig('./img/lecc01/ExportacionDeAcero.png', dpi=300, bbox_inches='tight')
```

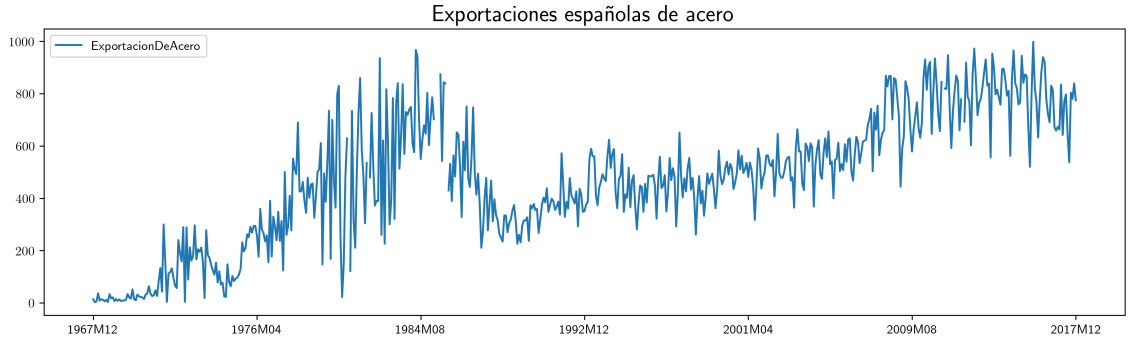

El desafío para el analista es

primero transformar los datos para lograr que sean "***estacionarios***"

y después transformar los datos estacionarios en "***ruido blanco***"(!!)
(!! *nuevo abuso del lenguaje que expresa que podemos asumir dichos datos transformados son realizaciones de un proceso de ruido blanco, i.e. de* <u>*media cero e incorrelado*</u>.)

2. Estacionariedad

El primer objetivo del *análisis de series temporales* es inferir la distribución de $\boldsymbol{X} = (X_t \mid t \in \mathbb{Z})$ usando una muestra finita (serie temporal) $\boldsymbol{x} = (x_t \mid t = 1 : n)$.

Así podremos intentar

Predecir datos futuros

Controlar datos futuros

Pero esto es inabordable si la evolución de los datos es inestable en el tiempo.

Por tanto, algún tipo de <u>estabilidad</u> (o <u>estacionariedad</u>) es necesaria.

2.1. Estacionariedad en sentido débil

Un proceso estocástico $\boldsymbol{X}$ se dice **estacionario** (*en sentido débil*) si para todo $t, k \in \mathbb{Z}$

$$E(X_t) = \mu \tag{1}$$

$$Cov(X_t, X_{t-k}) = \gamma_k \tag{2}$$

- (1) sugiere que las realizaciones de $\boldsymbol{X}$ aparecerán entorno al valor μ.
- (2) entre otras cosas, sugiere que la variabilidad de las realizaciones de $\boldsymbol{X}$ entorno a μ es constante, ya que para el caso particular $k = 0$

$$Cov(X_t, X_{t-0}) = Var(X_t) = \gamma_0 \quad \text{para todo } t,$$

  donde γ_0 es la varianza común a todas las variables aleatorias del proceso.

Es más, la desigualdad de Chebyshev

$$P\left(|X_t - \mu| \geq c\sigma\right) \leq \frac{1}{c^2}, \qquad \text{donde } \sigma = \sqrt{\gamma_0}$$

sugiere que para cualquier proceso estacionario (y un c grande), al pintar una realización, tan solo un pequeño porcentaje de los datos caerán fuera de la franja $(\mu - c\sigma, \mu + c\sigma)$.

```
# simulamos un proceso ARMA(p,q)
import statsmodels.api as sm
np.random.seed(12345)
arparams = np.array([.75, -.25])
maparams = np.array([.65, .35])
ar = np.r_[1, -arparams] # add zero-lag and negate
ma = np.r_[1, maparams] # add zero-lag
y = sm.tsa.arma_generate_sample(ar, ma, 450)
```

```
# creamos el gráfico de la serie simulada
plt.figure(figsize=(15,5))
plt.title("Realización de un proceso estacionario (con $\mu=0$)", fontsize=20)
plt.xlabel("Índice $t$", fontsize=16)
plt.ylabel("Valor", fontsize=16)
plt.tick_params(axis='both', labelsize=14)
plt.plot(y)
plt.savefig("./img/lecc01/stationaryTimeSeriesExample.png", dpi=300, bbox_inches='tight')
```

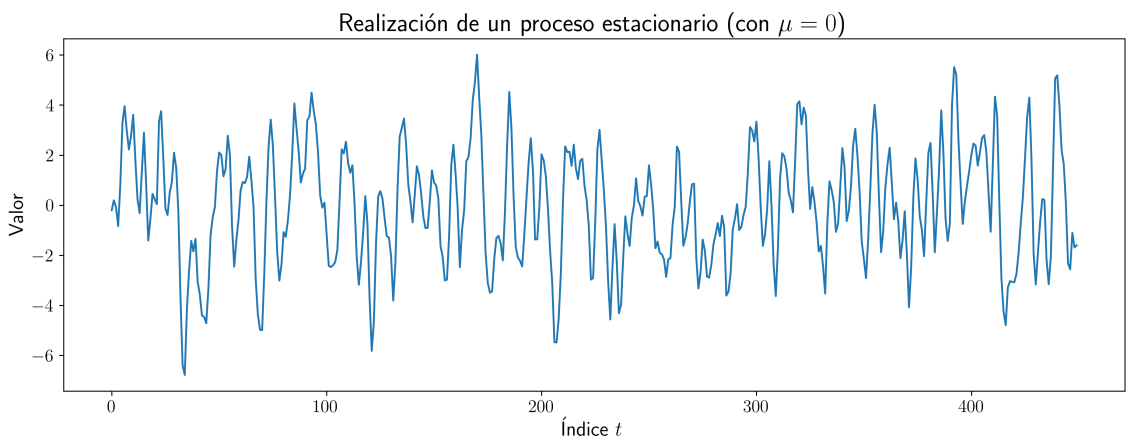

2.2. Función de autocovarianzas y función de autocorrelación

Cuando $\boldsymbol{X}$ es un proceso estocástico (débilmente) **estacionario**:

- La secuencia $(\gamma_k \mid k \in \mathbb{Z})$, donde $\gamma_k = Cov(X_t, X_{t-k})$ se denomina *función de autocovarianzas*.

Debido a la estacionariedad, la correlación entre X_t y X_{t+k} no depende de t; tan solo depende de la distancia k entre los índices de ambas variables.

- La secuencia $(\rho_k \mid k \in \mathbb{Z})$, donde $\rho_k = \frac{Cov(X_t, X_{t-k})}{\sqrt{Var(X_t)Var(X_{t-k})}} = \frac{\gamma_k}{\gamma_0}$ se denomina *función de autocorrelación* (ACF).

(*Estas secuencias serán fundamentales en el análisis de ciertos procesos estocásticos en futuras lecciones*).

3. Transformaciones de realizaciones de procesos estocásticos NO estacionarios

Un proceso estocástico $\boldsymbol{X} = (X_t \mid t \in \mathbb{Z})$ puede ser:

NO estacionario en media porque $E(X_t)$ depende de t.

NO estacionario en covarianza porque $Cov(X_t, X_{t-k})$ depende de t.

Separar o distinguir ambos tipos de no estacionariedad no es sencillo.

Veamos un ejemplo de serie temporal para la que

- no podemos asumir que sea realización de un proceso estocástico *estacionario*;
- y algunos intentos de transformación para obtener datos "**estacionarios**"(!!).
  (!! *recuerde que esta expresión, aunque extendida, es un abuso del lenguaje*).

3.1. Internat. airline passengers: monthly totals in thousands. Jan 49 Dec 60

```
# Leemos los datos de un fichero csv y generamos un dataframe de pandas.
OrigData = pd.read_csv('../datos/airline-passengers.csv')
#OrigData = pd.read_csv('../database/Datasets-master/airline-passengers.csv')
OrigData['Month']=pd.to_datetime(OrigData['Month'])
OrigData = OrigData.set_index(['Month'])
# print(OrigData.head())
```

```
plt.figure(figsize=(15,5))
plt.subplot(1, 2, 1)
plt.plot(OrigData['Passengers'])
plt.xlabel("Month", fontsize=16)
plt.ylabel(r"Number of Air Passengers, ($\boldsymbol{x}$)", fontsize=16)
plt.tick_params(axis='both', labelsize=14)
plt.subplot(1, 2, 2)
plt.hist(OrigData['Passengers'], edgecolor='white', bins=11)
plt.xlabel("Number of Air Passengers in thousands", fontsize=16)
plt.tick_params(axis='both', labelsize=14)
plt.tight_layout()
plt.savefig('./img/lecc01/airlinepass+hist.png', dpi=300, bbox_inches='tight')
```

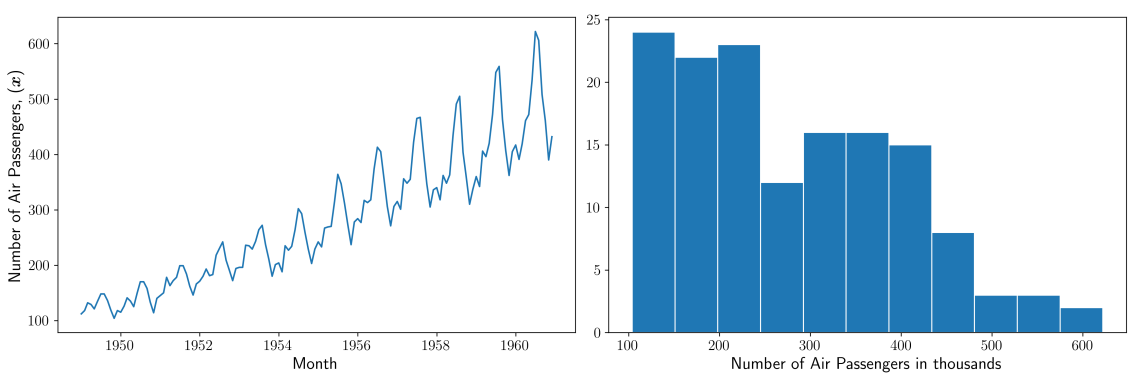

$$\boldsymbol{x} = (x_1, \dots x_{114})$$

Serie *"no estacionaria"* (!!):

- El nivel de la serie crece de año en año.
- La variabilidad estacional crece con el nivel (creciente diferencia entre el verano y el otoño).

3.1.1. Trasformación logarítmica de los datos

- Al aplicar la función logarítmica transformamos **monótonamente** los datos estabilizando la varianza cuando los valores son mayores que 0.567 (aprox.)
- Pero ocurre lo contrario cuando los valores son pequeños (aumenta el valor absoluto de aquellos entre 0 y 0.567 aprox.). De hecho, $\lim_{x \to 0} \ln(x) = -\infty$.

Recuerde que *el logaritmo no está definido para valores negativos.*

```
# Definir el rango de valores para x (empezando desde un número positivo ya que log(0) no está definido)
x = np.linspace(0.01, 7, 400)  # Valores de 0.1 a 10
# Calcular y = log(x)
y = np.log(x)

# Crear el gráfico
plt.figure(figsize=(16, 5))
plt.plot(x, y, label='y = ln(x)')
# Añadir etiquetas y título
plt.xlabel('x', fontsize=16)
plt.ylabel('ln(x)', fontsize=16)
plt.tick_params(axis='both', labelsize=14)
plt.title('Gráfico de la función logarítmica y = ln(x)', fontsize=20)
plt.axhline(0, color='black',linewidth=0.5)
plt.axvline(0, color='black',linewidth=0.5)
plt.grid(color = 'gray', linestyle = '--', linewidth = 0.5)
plt.legend(fontsize=20)
plt.savefig("./img/lecc01/funcion_logaritmica.png", dpi=300, bbox_inches='tight')
```

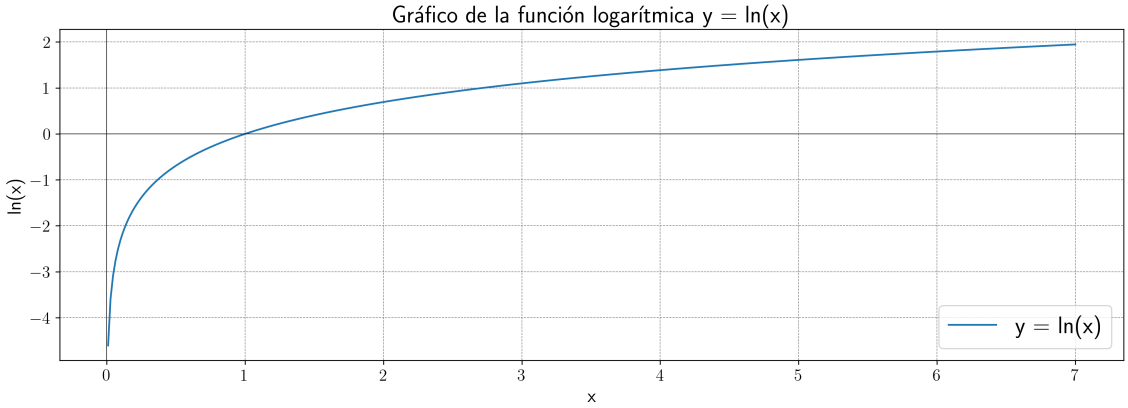


```
# Creamos un nuevo dataframe con los datos originales y varias transformaciones de los mismos
TransformedData = OrigData.copy()
TransformedData['dataLog'] = np.log(OrigData['Passengers'])
TransformedData['dataLogDiff'] = TransformedData['dataLog'].diff(1)
TransformedData['dataLogDiffDiff12'] = TransformedData['dataLogDiff'].diff(12)
```

Transformación logarítmica de los datos

```
plt.figure(figsize=(15,5))
plt.subplot(1, 2, 1)
plt.plot(TransformedData['dataLog'])
plt.xlabel("Month", fontsize=16)
plt.ylabel(r"Log-Passengers, ($\ln\boldsymbol{x}$)", fontsize=16)
plt.tick_params(axis='both', labelsize=14)
plt.subplot(1, 2, 2)
plt.hist(TransformedData['dataLog'], edgecolor='white', bins=11)
plt.xlabel(r"Log-Passengers, ($\ln\boldsymbol{x}$)", fontsize=16)
plt.tick_params(axis='both', labelsize=14)
plt.tight_layout()
plt.savefig('./img/lecc01/airlinepass_log+hist.png', dpi=300, bbox_inches='tight')
```

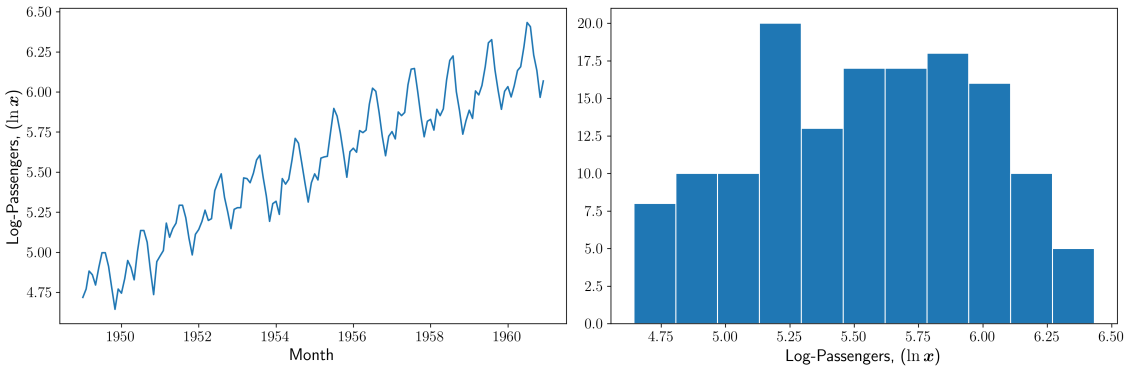

$$\ln \boldsymbol{x} = \Big(\ln(x_1), \ldots \ln(x_{114})\Big)$$

Ésta tampoco parece la realización de un proceso estocástico *estacionario*:

- Aunque la variabilidad estacional parece mantenerse de año en año,
- el nivel sigue creciendo de año en año.

3.1.2. Primera diferencia del logarítmo de los datos

```
plt.figure(figsize=(15,5))
plt.subplot(1, 2, 1)
plt.plot(TransformedData['dataLogDiff'])
plt.xlabel("Month", fontsize=16)
plt.ylabel(r"$\nabla\ln\boldsymbol{x}$", fontsize=16)
plt.tick_params(axis='both', labelsize=14)
plt.subplot(1, 2, 2)
plt.hist(TransformedData['dataLogDiff'], edgecolor='white', bins=11)
plt.xlabel(r"$\nabla\ln\boldsymbol{x}$", fontsize=16)
plt.tick_params(axis='both', labelsize=14)
plt.tight_layout()
plt.savefig('./img/lecc01/airlinepass_logDiff+hist.png', dpi=300, bbox_inches='tight')
```

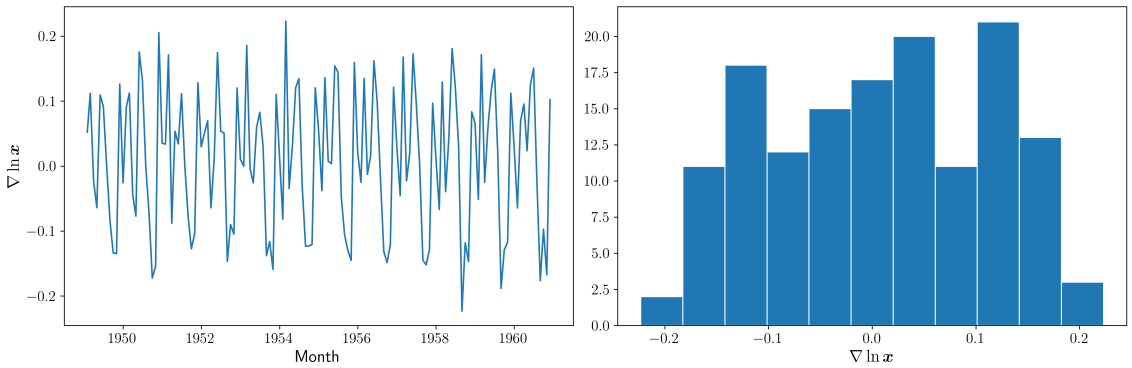

$$\boldsymbol{y} = \nabla \ln \boldsymbol{x} = \Big(\big[\ln(x_2) - \ln(x_1) \big], \ldots \ \big[\ln(x_{114}) - \ln(x_{113}) \big] \Big)$$

Esta serie tampoco parece "*estacionaria*"(!!):

- Hay un *persistente* componente periódico (de naturaleza estacional) debido a que hay pocos viajes en otoño y muchos en Navidad, Semana Santa y verano (i.e., el número esperado de viajeros parece cambiar en función del mes o estación).

3.1.3. Diferencia estacional de la primera diferencia del logarítmo de los datos

```
plt.figure(figsize=(15,5))
plt.subplot(1, 2, 1)
plt.plot(TransformedData['dataLogDiffDiff12'])
plt.xlabel("Month", fontsize=16)
plt.ylabel(r"$\nabla_{12}(\nabla\ln\boldsymbol{x})$", fontsize=16)
plt.tick_params(axis='both', labelsize=14)
plt.subplot(1, 2, 2)
plt.hist(TransformedData['dataLogDiffDiff12'], edgecolor='white', bins=11)
plt.xlabel(r"$\nabla_{12}(\nabla\ln\boldsymbol{x})$", fontsize=16)
plt.tick_params(axis='both', labelsize=14)
plt.tight_layout()
plt.savefig('./img/lecc01/airlinepass_logDiffDiff12+hist.png', dpi=300, bbox_inches='tight')
```

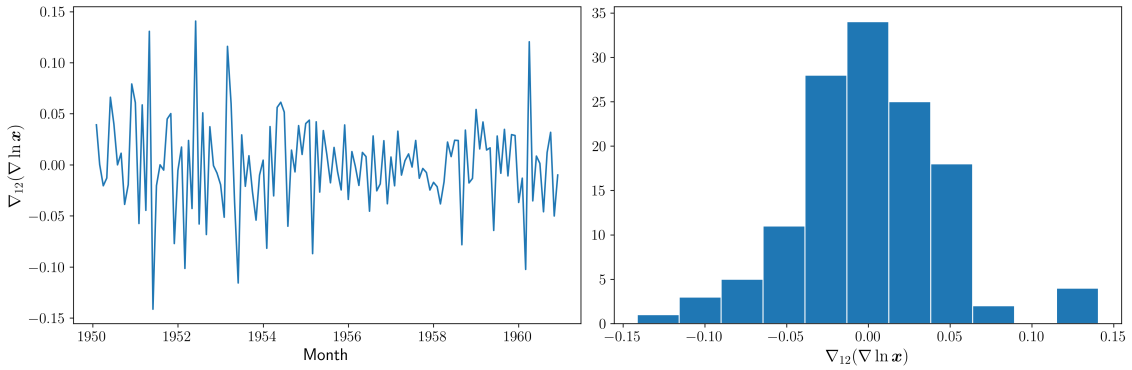

$$\boldsymbol{z} = \nabla_{12}(\nabla \ln \boldsymbol{x}) = \nabla_{12}(\boldsymbol{y}) = \Big((y_{13} - y_1), \ldots \ (y_{113} - y_{101}) \Big)$$

- Esta serie tiene el aspecto de realización de un proceso *estacionario*.
- De propina, el histograma sugiere una distribución aproximadamente Gaussiana.

3.2. Tasa logarítmica de crecimiento

```
START = 100
UnoPorCiento = lambda n0, t: n0 if t<=1 else 1.01 * UnoPorCiento(n0, t-1)
TasaLogCrecimiento = pd.DataFrame({'$y_t$':[UnoPorCiento(START,t+1) for t in range(10)]})
TasaLogCrecimiento[r'$\frac{y_t-y_{t-1}}{y_{t-1}}$'] = TasaLogCrecimiento['$y_t$'].pct_change()
TasaLogCrecimiento[r'$\ln y_t$'] = np.log(TasaLogCrecimiento['$y_t$'])
TasaLogCrecimiento[r'$\;(\ln y_t-\ln y_{t-1})$'] = TasaLogCrecimiento[r'$\ln y_t$']-TasaLogCrecimiento[r'$\ln y_t$'].shift(+1)
TasaLogCrecimiento[r'$\frac{y_t-y_{0}}{y_{0}}$'] = TasaLogCrecimiento['$y_t$'].apply(lambda x: ((x/START)-1))
TasaLogCrecimiento[r'$\;(\ln y_t-\ln y_{0})$'] = TasaLogCrecimiento[r'$\ln y_t$']-TasaLogCrecimiento[r'$\ln y_t$'].iloc[0]
```

La tasa logarítmica de variación de $\boldsymbol{y}$ se define como $z_t = \ln y_t - \ln y_{t-1}$; es decir

$$\boldsymbol{z} = \nabla \ln \boldsymbol{y} = \Big(\big[\ln(y_2) - \ln(y_1) \big], \ldots \ \big[\ln(y_n) - \ln(y_{n-1}) \big] \Big)$$

y se *aproxima* a la tasa de crecimiento (en tanto por uno) si el incremento es pequeño.

	y_t	$\frac{y_t-y_{t-1}}{y_{t-1}}$	$\ln y_t$	$(\ln y_t - \ln y_{t-1})$	$\frac{y_t-y_0}{y_0}$	$(\ln y_t - \ln y_0)$
0	100.000000	NaN	4.605170	NaN	0.000000	0.000000
1	101.000000	0.01	4.615121	0.00995	0.010000	0.009950
2	102.010000	0.01	4.625071	0.00995	0.020100	0.019901
3	103.030100	0.01	4.635021	0.00995	0.030301	0.029851
4	104.060401	0.01	4.644972	0.00995	0.040604	0.039801
5	105.101005	0.01	4.654922	0.00995	0.051010	0.049752
6	106.152015	0.01	4.664872	0.00995	0.061520	0.059702
7	107.213535	0.01	4.674823	0.00995	0.072135	0.069652
8	108.285671	0.01	4.684773	0.00995	0.082857	0.079603
9	109.368527	0.01	4.694723	0.00995	0.093685	0.089553

3.2.1. Comentarios y/o interpretaciones de los datos transformados

Transformación de la serie temporal $\boldsymbol{y} = \{y_t\},\ t = 1 : n$	Comentario y/o interpretación
$\boldsymbol{z} = \ln \boldsymbol{y} = \{\ln y_t\}$	A veces independiza la volatilidad del nivel. A veces induce normalidad.
$\boldsymbol{z} = \nabla \boldsymbol{y} = \{y_t - y_{t-1}\}$	Indica al crecimiento absoluto entre periodos consecutivos.
$\boldsymbol{z} = \nabla \ln \boldsymbol{y}$ $= \{\ln y_t - \ln y_{t-1}\}$	Tasa logarítmica de crecimiento. Aproximación del crecimiento relativo entre periodos consecutivos.
$\boldsymbol{z} = \nabla\nabla \ln \boldsymbol{y} = \nabla^2 \ln \boldsymbol{y}$	Cambio en la tasa log. de crecimiento. Indica la aceleración en el crecimiento relativo.
$\boldsymbol{z} = \nabla_s \ln \boldsymbol{y}$ $= \{\ln y_t - \ln y_{t-s}\}$	Tasa log. de crecimiento acumulada en un ciclo estacional completo (s períodos). Cuando el período estacional es de un año, se conoce como tasa anual o tasa interanual de crecimiento.
$\boldsymbol{z} = \nabla\nabla_s \ln \boldsymbol{y}$	Cambio en la tasa log. de crecimiento acumulada en un ciclo estacional completo. Es un indicador de aceleración en el crecimiento acumulado.